

# Regressions- och tidsserieanalys

## Föreläsning 7 - Icke-linjär regression. Polynom- och exponentiella samband

**Mattias Villani**

Statistiska institutionen  
Stockholms universitet

Institutionen för datavetenskap  
Linköpings universitet



[mattiasvillani.com](https://mattiasvillani.com)







@matvil



[mattiasvillani](https://github.com/mattiasvillani)

- Utvärdera och **välja modeller baserat på prognosförmåga**
- **Polynomregression**
- **Exponentiella modeller**

# Överanpassa data



# Prognosförmåga på testdata

- Dela upp observationer i två delmängder:
  - ▶ **Träningsdata** för att skatta modellens parametrar.
  - ▶ **Testdata** för att utvärdera modellens prediktioner.
- Modellen får aldrig chans att anpassa sig till testdata.
- Prediktionsmått: **kvadrerade prediktionsfel på testdata**

$$\text{SSE}_{\text{test}} = \sum_{j=1}^{n_{\text{test}}} (y_j - \hat{y}_j)^2$$

- Observera:
  - ▶ summan är över observationerna i testdata.
  - ▶ modellen som ger  $\hat{y}_j$  är **skattad enbart på träningsdata**.
  - ▶ **överanpassning** på träningsdata  $\Rightarrow$  dåliga prediktioner på testdata.

# Korsvalidering

- Vilka observationer ska vara i träning respektive test?
- Regression: **Korsvalidering**. Dela upp data i  $K$  st **folds**:

Fold 1			Fold 2			Fold 3			Fold 4		
biltyp	mpg	hp	biltyp	mpg	hp	biltyp	mpg	hp	biltyp	mpg	hp
Hornet Sportabout	18.7	0.52	Hornet Sportabout	18.7	0.52	Hornet Sportabout	18.7	0.52	Hornet Sportabout	18.7	0.52
Fiat X1-9	27.3	0.20	Fiat X1-9	27.3	0.20	Fiat X1-9	27.3	0.20	Fiat X1-9	27.3	0.20
Merc 450SL	17.3	0.54	Merc 450SL	17.3	0.54	Merc 450SL	17.3	0.54	Merc 450SL	17.3	0.54
Merc 450SLC	15.2	0.54	Merc 450SLC	15.2	0.54	Merc 450SLC	15.2	0.54	Merc 450SLC	15.2	0.54
Merc 240D	24.4	0.19	Merc 240D	24.4	0.19	Merc 240D	24.4	0.19	Merc 240D	24.4	0.19
Duster 360	14.3	0.73	Duster 360	14.3	0.73	Duster 360	14.3	0.73	Duster 360	14.3	0.73
Datsun 710	22.8	0.28	Datsun 710	22.8	0.28	Datsun 710	22.8	0.28	Datsun 710	22.8	0.28
Ferrari Dino	19.7	0.52	Ferrari Dino	19.7	0.52	Ferrari Dino	19.7	0.52	Ferrari Dino	19.7	0.52
Ford Pantera L	15.8	0.79	Ford Pantera L	15.8	0.79	Ford Pantera L	15.8	0.79	Ford Pantera L	15.8	0.79
Pontiac Firebird	19.2	0.52	Pontiac Firebird	19.2	0.52	Pontiac Firebird	19.2	0.52	Pontiac Firebird	19.2	0.52
Toyota Corona	21.5	0.29	Toyota Corona	21.5	0.29	Toyota Corona	21.5	0.29	Toyota Corona	21.5	0.29
AMC Javelin	15.2	0.45	AMC Javelin	15.2	0.45	AMC Javelin	15.2	0.45	AMC Javelin	15.2	0.45
Camaro Z28	13.3	0.73	Camaro Z28	13.3	0.73	Camaro Z28	13.3	0.73	Camaro Z28	13.3	0.73
Fiat 128	32.4	0.20	Fiat 128	32.4	0.20	Fiat 128	32.4	0.20	Fiat 128	32.4	0.20
Merc 280C	17.8	0.37	Merc 280C	17.8	0.37	Merc 280C	17.8	0.37	Merc 280C	17.8	0.37
Lotus Europa	30.4	0.34	Lotus Europa	30.4	0.34	Lotus Europa	30.4	0.34	Lotus Europa	30.4	0.34
Cadillac Fleetwood	10.4	0.61	Cadillac Fleetwood	10.4	0.61	Cadillac Fleetwood	10.4	0.61	Cadillac Fleetwood	10.4	0.61
Chrysler Imperial	14.7	0.69	Chrysler Imperial	14.7	0.69	Chrysler Imperial	14.7	0.69	Chrysler Imperial	14.7	0.69
Mazda RX4	21	0.33	Mazda RX4	21	0.33	Mazda RX4	21	0.33	Mazda RX4	21	0.33
Volvo 142E	21.4	0.33	Volvo 142E	21.4	0.33	Volvo 142E	21.4	0.33	Volvo 142E	21.4	0.33
Mazda RX4 Wag	21	0.33	Mazda RX4 Wag	21	0.33	Mazda RX4 Wag	21	0.33	Mazda RX4 Wag	21	0.33
Merc 230	22.8	0.28	Merc 230	22.8	0.28	Merc 230	22.8	0.28	Merc 230	22.8	0.28
Toyota Corolla	33.9	0.19	Toyota Corolla	33.9	0.19	Toyota Corolla	33.9	0.19	Toyota Corolla	33.9	0.19
Merc 280	19.2	0.37	Merc 280	19.2	0.37	Merc 280	19.2	0.37	Merc 280	19.2	0.37
Dodge Challenger	15.5	0.45	Dodge Challenger	15.5	0.45	Dodge Challenger	15.5	0.45	Dodge Challenger	15.5	0.45
Lincoln Continental	10.4	0.64	Lincoln Continental	10.4	0.64	Lincoln Continental	10.4	0.64	Lincoln Continental	10.4	0.64
Volant	18.1	0.31	Volant	18.1	0.31	Volant	18.1	0.31	Volant	18.1	0.31
Honda Civic	30.4	0.16	Honda Civic	30.4	0.16	Honda Civic	30.4	0.16	Honda Civic	30.4	0.16
Hornet 4 Drive	21.4	0.33	Hornet 4 Drive	21.4	0.33	Hornet 4 Drive	21.4	0.33	Hornet 4 Drive	21.4	0.33
Merc 450SE	16.4	0.54	Merc 450SE	16.4	0.54	Merc 450SE	16.4	0.54	Merc 450SE	16.4	0.54
Maserati Bora	15	1.00	Maserati Bora	15	1.00	Maserati Bora	15	1.00	Maserati Bora	15	1.00
Porsche 914-2	26	0.27	Porsche 914-2	26	0.27	Porsche 914-2	26	0.27	Porsche 914-2	26	0.27

Träning

Test

# Korsvalidering

Fold 1			Fold 2			Fold 3			Fold 4		
testyp	avg	hp	testyp	avg	hp	testyp	avg	hp	testyp	avg	hp
Mercedes Sprinter	28.7	0.52	Mercedes Sprinter	28.7	0.52	Mercedes Sprinter	28.7	0.52	Mercedes Sprinter	28.7	0.52
Fiat X1-9	27.3	0.28	Fiat X1-9	27.3	0.28	Fiat X1-9	27.3	0.28	Fiat X1-9	27.3	0.28
Mercedes 450SL	17.3	0.54	Mercedes 450SL	17.3	0.54	Mercedes 450SL	17.3	0.54	Mercedes 450SL	17.3	0.54
Mercedes 450SL C	15.2	0.54	Mercedes 450SL C	15.2	0.54	Mercedes 450SL C	15.2	0.54	Mercedes 450SL C	15.2	0.54
Mercedes 240D	24.4	0.18	Mercedes 240D	24.4	0.18	Mercedes 240D	24.4	0.18	Mercedes 240D	24.4	0.18
Datsun 280	14.3	0.19	Datsun 280	14.3	0.19	Datsun 280	14.3	0.19	Datsun 280	14.3	0.19
Datsun 720	22.8	0.28	Datsun 720	22.8	0.28	Datsun 720	22.8	0.28	Datsun 720	22.8	0.28
Ford Focus	19.7	0.52	Ford Focus	19.7	0.52	Ford Focus	19.7	0.52	Ford Focus	19.7	0.52
Ford Focus L	25.8	0.18	Ford Focus L	25.8	0.18	Ford Focus L	25.8	0.18	Ford Focus L	25.8	0.18
Pontiac Firebird	19.2	0.52	Pontiac Firebird	19.2	0.52	Pontiac Firebird	19.2	0.52	Pontiac Firebird	19.2	0.52
Toyota Corolla	21.5	0.28	Toyota Corolla	21.5	0.28	Toyota Corolla	21.5	0.28	Toyota Corolla	21.5	0.28
AMC Jeeps	19.7	0.45	AMC Jeeps	19.7	0.45	AMC Jeeps	19.7	0.45	AMC Jeeps	19.7	0.45
Canova Z28	13.3	0.18	Canova Z28	13.3	0.18	Canova Z28	13.3	0.18	Canova Z28	13.3	0.18
Ford 128	12.4	0.28	Ford 128	12.4	0.28	Ford 128	12.4	0.28	Ford 128	12.4	0.28
Mercedes 280C	17.8	0.37	Mercedes 280C	17.8	0.37	Mercedes 280C	17.8	0.37	Mercedes 280C	17.8	0.37
Lexus ES300	30.4	0.54	Lexus ES300	30.4	0.54	Lexus ES300	30.4	0.54	Lexus ES300	30.4	0.54
Cadillac Fleetwood	10.4	0.82	Cadillac Fleetwood	10.4	0.82	Cadillac Fleetwood	10.4	0.82	Cadillac Fleetwood	10.4	0.82
Chrysler Imperial	14.7	0.88	Chrysler Imperial	14.7	0.88	Chrysler Imperial	14.7	0.88	Chrysler Imperial	14.7	0.88
Mercedes 190	21	0.28	Mercedes 190	21	0.28	Mercedes 190	21	0.28	Mercedes 190	21	0.28
Volvo 140G	21.4	0.38	Volvo 140G	21.4	0.38	Volvo 140G	21.4	0.38	Volvo 140G	21.4	0.38
Mercedes 190 W126	21	0.28	Mercedes 190 W126	21	0.28	Mercedes 190 W126	21	0.28	Mercedes 190 W126	21	0.28
Mercedes 190	21.8	0.28	Mercedes 190	21.8	0.28	Mercedes 190	21.8	0.28	Mercedes 190	21.8	0.28
Toyota Corolla	33.9	0.18	Toyota Corolla	33.9	0.18	Toyota Corolla	33.9	0.18	Toyota Corolla	33.9	0.18
Mercedes 280	29.2	0.37	Mercedes 280	29.2	0.37	Mercedes 280	29.2	0.37	Mercedes 280	29.2	0.37
Dodge Challenger	15.5	0.45	Dodge Challenger	15.5	0.45	Dodge Challenger	15.5	0.45	Dodge Challenger	15.5	0.45
Lexus Continental	10.4	0.88	Lexus Continental	10.4	0.88	Lexus Continental	10.4	0.88	Lexus Continental	10.4	0.88
Volvo	18.1	0.32	Volvo	18.1	0.32	Volvo	18.1	0.32	Volvo	18.1	0.32
Mercedes Civic	30.4	0.18	Mercedes Civic	30.4	0.18	Mercedes Civic	30.4	0.18	Mercedes Civic	30.4	0.18
Mercedes 450SE	21.4	0.28	Mercedes 450SE	21.4	0.28	Mercedes 450SE	21.4	0.28	Mercedes 450SE	21.4	0.28
Mercedes 450SE	18.4	0.54	Mercedes 450SE	18.4	0.54	Mercedes 450SE	18.4	0.54	Mercedes 450SE	18.4	0.54
Mercedes 280	15	1.08	Mercedes 280	15	1.08	Mercedes 280	15	1.08	Mercedes 280	15	1.08
Mercedes 280-2	26	0.27	Mercedes 280-2	26	0.27	Mercedes 280-2	26	0.27	Mercedes 280-2	26	0.27

Training

Test

## ■ Prognosfel i testdata

$$\text{MSE}_{cv} = \frac{\sum_{j=1}^n (y_j - \hat{y}_j^*)^2}{n}$$

## ■ Lättare att tolka Root MSE

$$\text{RMSE}_{cv} = \sqrt{\text{MSE}_{cv}}$$

## ■ Prognosförmåga på testdata kan användas för modellval.

## ■ För mer info: masterkursen Maskininlärning 7.5 hp.

# Kvadratisk regression

## ■ Kvadratisk regression

$$y = a + b_1x + b_2x^2$$

## ■ ... är **multipl regression med två förklarande variabler**:

- ▶  $x_1 = x$
- ▶  $x_2 = x^2$

## ■ **Populationsmodell**:

$$y = \alpha + \beta_1x + \beta_2x^2 + \varepsilon$$

## ■ **Minsta-kvadratmetoden** för att beräkna $a$ , $b_1$ och $b_2$ ! 🤔❤️

## ■ Kvadratisk regression **icke-linjär i $x$** , men linjär i $\alpha$ , $\beta_1$ och $\beta_2$ .


# Kvadratisk regression - excel

	A	B	C	D
1		mpg (y)	hp (x)	$x^2$
2	Mazda RX4	21.000	0.328	0.108
3	Mazda RX4 Wag	21.000	0.328	0.108
4	Datsun 710	22.800	0.278	0.077
5	Hornet 4 Drive	21.400	0.328	0.108
6	Hornet Sportabout	18.700	0.522	0.273
7	Valiant	18.100	0.313	0.098
8	Duster 360	14.300	0.731	0.535
9	Merc 240D	24.400	0.185	0.034
10	Merc 230	22.800	0.284	0.080
11	Merc 280	19.200	0.367	0.135
12	Merc 280C	17.800	0.367	0.135
13	Merc 450SE	16.400	0.537	0.289
14	Merc 450SL	17.300	0.537	0.289
15	Merc 450SLC	15.200	0.537	0.289
16	Cadillac Fleetwood	10.400	0.612	0.374
17	Lincoln Continental	10.400	0.642	0.412
18	Chrysler Imperial	14.700	0.687	0.471
19	Fiat 128	32.400	0.197	0.039
20	Honda Civic	30.400	0.155	0.024
21	Toyota Corolla	33.900	0.194	0.038
22	Toyota Corona	21.500	0.290	0.084
23	Dodge Challenger	15.500	0.448	0.200
24	AMC Javelin	15.200	0.448	0.200
25	Camaro Z28	13.300	0.731	0.535
26	Pontiac Firebird	19.200	0.522	0.273
27	Fiat X1-9	27.300	0.197	0.039
28	Porsche 914-2	26.000	0.272	0.074
29	Lotus Europa	30.400	0.337	0.114
30	Ford Pantera L	15.800	0.788	0.621
31	Ferrari Dino	19.700	0.522	0.273
32	Maserati Bora	15.000	1.000	1.000
33	Volvo 142E	21.400	0.325	0.106


- Notera att hp är normaliserad genom att dividera med  $\max(\text{hp})$  i stickprovet.  
Bli **numeriskt stabilare om man normaliserar** så.




# mtcars data - linjär regression mot hp



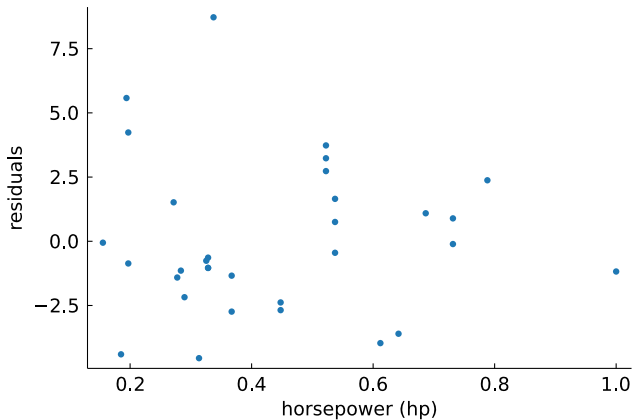
# mtcars data - residualer linjär regression



# mtcars data - kvadratisk regression mot hp




# mtcars data - residualer kvadratisk regression



# Linjär regression - tolkning $b$

regressionslinje :  $y = a + b \cdot x = 1215 + 6641 \cdot x$



# Tolkningar av parametrar i kvadratisk regression

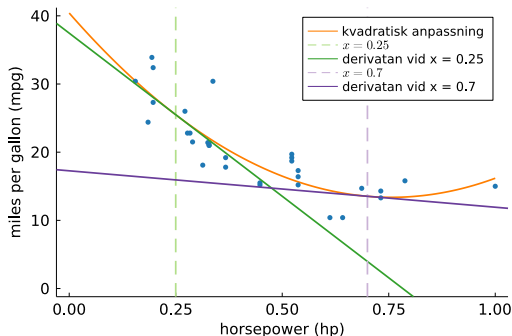
## ■ Kvadratisk regression

$$y = a + b_1x + b_2x^2$$

## ■ Regressionskoefficienterna tolkas som derivator:

$$\frac{dy}{dx} = b_1 + 2b_2 \cdot x$$

## ■ Effekten av en liten förändring $\Delta x$ i $x$ beror på $x$ själv:



# Polynomregression

## ■ Polynomregression

$$y = a + b_1x + b_2x^2 + \dots + b_kx^k$$

- Polynomregression av ordning  $k$  är detsamma som multipel regression med  $k$  förklarande variabler:

- ▶  $x_1 = x$
- ▶  $x_2 = x^2$
- ▶  $\vdots$
- ▶  $x_k = x^k$

## ■ Populationsmodell:

$$y = \alpha + \beta_1x + \beta_2x^2 + \dots + \beta_kx^k + \varepsilon$$


- **Minsta-kvadratmetoden** kan användas för att beräkna  $a, b_1, \dots, b_k$ ! 😍
- Polynomregression är **icke-linjär i  $x$** , men linjär i  $\alpha, \beta_1, \dots, \beta_k$ .

# Polynomregression - excel


	A	B	C	D	E	F
1		mpg (y)	hp (x)	$x^2$	$x^3$	$x^4$
2	Mazda RX4	21.000	0.328	0.108	0.035	0.012
3	Mazda RX4 Wag	21.000	0.328	0.108	0.035	0.012
4	Datsun 710	22.800	0.278	0.077	0.021	0.006
5	Hornet 4 Drive	21.400	0.328	0.108	0.035	0.012
6	Hornet Sportabout	18.700	0.522	0.273	0.143	0.074
7	Valiant	18.100	0.313	0.098	0.031	0.010
8	Duster 360	14.300	0.731	0.535	0.391	0.286
9	Merc 240D	24.400	0.185	0.034	0.006	0.001
10	Merc 230	22.800	0.284	0.080	0.023	0.006
11	Merc 280	19.200	0.367	0.135	0.049	0.018
12	Merc 280C	17.800	0.367	0.135	0.049	0.018
13	Merc 450SE	16.400	0.537	0.289	0.155	0.083
14	Merc 450SL	17.300	0.537	0.289	0.155	0.083
15	Merc 450SLC	15.200	0.537	0.289	0.155	0.083
16	Cadillac Fleetwood	10.400	0.612	0.374	0.229	0.140
17	Lincoln Continental	10.400	0.642	0.412	0.264	0.170
18	Chrysler Imperial	14.700	0.687	0.471	0.324	0.222
19	Fiat 128	32.400	0.197	0.039	0.008	0.002




# mtcars data - kubisk regression mot hp




## mtcars data - polynomregression ordning 4





## mtcars data - polynomregression ordning 5



# mtcars data - polynomregression ordning 10




## mtcars data - $R^2$ och RMSE-CV( $K = 4$ )



# mtcars data - $R^2$ och $R^2_{\text{adjusted}}$

## ■ Justerad $R^2$

$$R^2_{\text{adjusted}} = 1 - \frac{s_e^2}{s_y^2} = 1 - \frac{\text{MSE}}{\text{MST}}$$



# L2-regularisering (Ridge regression)



- För många x-variabler  $\Rightarrow$  MK-metoden överanpassar data.
- Modellen är överparametriserad.
- Variabelselektion (t ex forward selection) är en lösning.
- L2-regularisering minimerar en straffad SSE:

$$Q_{\lambda} = \sum_{i=1}^n (y_i - a - b_1 x_{1i} - \dots - b_k x_{ki})^2 + \lambda \cdot \sum_{j=1}^k b_j^2$$

- Stort  $\lambda$  kommer krympa estimaten av  $b_j$  mot noll.
- Skattningen är nu biased, men har lägre varians.
- Bias-Variance trade-off.

---

<sup>1</sup>Videon [regularisering.mp4](#) finns i Videos mappen på Athena.

- L1-regularisering (Lasso) straffar med **absolutbelopp**:

$$Q_- = \sum_{i=1}^n (y_i - a - b_1 x_{1i} - \dots - b_k x_{ki})^2 + \lambda \cdot \sum_{j=1}^k |b_j|$$


- Lasso har två effekter:
  - ▶ krymper  $b_j$  mot noll (**shrinkage**)
  - ▶ kan sätta vissa  $b_j$  exakt till noll (**selection**)
- glmnet paketet i R gör både L1 och L2 regularisering och mer.
- Lasso är extremt populär. Go-to när man har väldigt många förklarande variabler.

---

<sup>2</sup>Videon [regularisering.mp4](#) finns i Videos mappen på Athena.



# Lasso regularisering polynom ordning 10



$$Q_{\lambda} = \sum_{i=1}^n (y_i - a - b_1 x_{1i} - \dots - b_k x_{ki})^2 + \lambda \cdot \sum_{j=1}^k |b_j|$$

■  $a = 35.80$ ,  $b_1 = -43.58$ ,  $b_3 = 23.32$ .

■  $b_2 = 0$  och  $b_4 = \dots = b_{10} = 0$  (**variabelselektion**).

# Exponentiella samband 3

- Du sätter in 200 kr på banken till 5% årsränta. Utveckling:

$$1 \text{ år: } 200 \cdot 1.05 = 210.000 \text{ kr}$$

$$2 \text{ år: } 200 \cdot 1.05^2 = 220.500 \text{ kr}$$

$$3 \text{ år: } 200 \cdot 1.05^3 = 231.525 \text{ kr}$$

- Efter  $x$  år:  $200 \cdot 1.05^x$ . **Exponentiell tillväxt**. Samma procentuella ökning varje år.

- **Exponentiellt samband**

$$y = a \cdot b^x$$

- $a$  är det **initiala** beloppet eller storheten.
- $b$  bestämmer **tillväxttakten**

$$b > 1 \text{ ökande}$$

$$b < 1 \text{ minskade}$$

$$b = 1 \text{ konstant (nolltillväxt)}$$

# Exponentiell regression

## ■ Exponentiell regression:

$$y = a \cdot b^x$$

## ■ Logaritmregler (10-logaritmer $\log = \log_{10}$ )

$\log(a \cdot b) = \log a + \log b$  ("log av produkten är summan av log")

$\log b^x = x \log b$  ("exponenten hoppar ner framför")

## ■ Logaritmera båda sidor

$$\underbrace{\log y}_{\tilde{y}} = \underbrace{\log a}_{\tilde{a}} + \underbrace{\log b \cdot x}_{\tilde{b}x}$$

$$\tilde{y} = \tilde{a} + \tilde{b}x$$

$$\tilde{a} = \log a$$

$$\tilde{b} = \log b$$

## ■ Skatta $\tilde{a}$ och $\tilde{b}$ med **minsta-kvadrat** med $\tilde{y} = \log y$ !

## ■ Skattningar för $a$ och $b$ fås genom **anti-logaritmering**

$$a = 10^{\tilde{a}} \quad \text{och} \quad b = 10^{\tilde{b}}$$



# Potensregel logarithmer

$$\log(\text{😅}) = \text{💧} \log(\text{😄})$$

# Exponentiell regression

■ **Responsvariabler** med **enbart positiva värden** (t ex lön):

- ▶ **Normalfördelning** ofta **opassande** pga **skevhets**.
- ▶ **kan ge prediktioner för  $y$  som är negativa**.



# Exponentiell regression

- **Populationsmodell:**

$$y = \alpha \cdot \beta^x \varepsilon$$

- **Logaritmen av feltermen**  $\varepsilon$  är **normalfördelad**.

- Vi säger att feltermen  $\varepsilon$  är **lognormal** fördelad. Innebär  $\varepsilon > 0$ .

- **Logaritmera** för att göra modellen **linjär**!

$$\underbrace{\log y}_{\tilde{y}} = \underbrace{\log \alpha}_{\tilde{\alpha}} + \underbrace{\log \beta}_{\tilde{\beta}} \cdot x + \underbrace{\log \varepsilon}_{\tilde{\varepsilon}}$$

$$\tilde{y} = \tilde{\alpha} + \tilde{\beta} \cdot x + \tilde{\varepsilon}, \quad \tilde{\varepsilon} \sim N(0, \sigma_{\tilde{\varepsilon}}^2).$$

- $t$ -test för  $H_0 : \tilde{\beta} = 0$  är **test för konstant tillväxt**  $\beta = 1$ .

- **Prediktion** för  $x = x_0$ :

$$\hat{y} = a \cdot b^{x_0} = 10^{\tilde{a}} \cdot (10^{\tilde{b}})^{x_0} = 10^{\tilde{a} + \tilde{b}x_0}$$

- Dvs, gör prediktion  $\widehat{\log y}$  och “anti-logga” för prognosen för  $\hat{y}$ .

# Kinesisk tillväxt

	A	B	C	D	E
1	year	gdp	gdpgrowth	log10(gdp)	t = year - 1999
2	2000	959.3725	9.86	2.981987265	1
3	2001	1053.1082	9.77	3.022472994	2
4	2002	1148.5083	9.06	3.060134138	3
5	2003	1288.6433	12.2	3.11013272	4
6	2004	1508.6681	17.07	3.178593708	5
7	2005	1753.4178	16.22	3.243885411	6
8	2006	2099.2294	19.72	3.3220599	7
9	2007	2693.9701	28.33	3.430392771	8
10	2008	3468.3046	28.74	3.540117232	9
11	2009	3832.2364	10.49	3.583452292	10
12	2010	4550.4531	18.74	3.658054643	11
13	2011	5618.1323	23.46	3.749591962	12
14	2012	6316.9183	12.44	3.80050526	13
15	2013	7050.6463	11.62	3.848228929	14
16	2014	7678.5995	8.91	3.885282016	15
17	2015	8066.9426	5.06	3.906708967	16
18	2016	8147.9377	1	3.9110477	17
19	2017	8879.4387	8.98	3.948385513	18
20	2018	9976.6771	12.36	3.998985916	19
21	2019	10216.6303	2.41	4.009307678	20
22	2020	10500.3956	2.78	4.021205661	21
23					

# Kinesisk tillväxt 2000-2013

Coefficients:


	Coef.	Std. Error	t	Pr(> t )	Lower 95%	Upper 95%
(Intercept)	2.8498	0.0192341	148.16	<1e-18	2.80747	2.89214
year	0.0729005	0.00242327	30.08	<1e-11	0.067567	0.0782341

■  $\tilde{a} = 2.8498$ , så  $a = 10^{\tilde{a}} = 707.62376$ .

■  $\tilde{b} = 0.0729005$ , så  $b = 10^{\tilde{b}} = 10^{0.0729005} = 1.18277$ .



# Kinesisk tillväxt 2000-2013



# Kinesisk tillväxt 2000-2021

